

# Análise Multivariada

## Decomposição em Valores Singulares

Prof. George von Borries

Departamento de Estatística  
Universidade de Brasília

2023



## Decomposição em Valores Singulares (SVD)

A **Decomposição Espectral (SD)** de uma matriz quadrada  $\mathbf{A}_{d \times d}$  pode ser expressa por  $\mathbf{A} = \mathbf{X}\mathbf{D}\mathbf{X}^T$  em que

- $\mathbf{X} = [\mathbf{X}_{(1)}, \dots, \mathbf{X}_{(d)}]$ , é a matriz de autovetores normalizados de  $\mathbf{A}$ ;
- $\mathbf{X}\mathbf{X}^T = \mathbf{X}^T\mathbf{X} = \mathbf{I}$
- $\mathbf{A}\mathbf{X}_{(j)} = \lambda_j\mathbf{X}_{(j)}$ , sendo  $\lambda_j$  o  $j$ -ésimo autovalor de  $\mathbf{A}$ ;
- $\mathbf{D} = \text{diag}(\lambda_1, \dots, \lambda_d)$ .

A **SVD** é uma generalização da **SD** para matrizes não quadradas.



## Definição (Decomposição em Valores Singulares)

Uma matriz  $\mathbf{P}_{n \times d}$  (valores reais) pode ser sempre escrita como

$$\mathbf{P} = \mathbf{U}\mathbf{D}\mathbf{V}^T$$

em que

- $\mathbf{U}$  é uma matriz de colunas ortonormais contendo  $n$  autovetores da matriz  $\mathbf{P}\mathbf{P}^T$  (“left singular vectors”).
  - $\mathbf{V}$  é uma matriz de colunas ortonormais contendo  $d$  autovetores da matriz  $\mathbf{P}^T\mathbf{P}$  (“right singular vectors”).
  - $\mathbf{D}$  é uma matriz  $n \times d$  diagonal com  $\sqrt{\lambda_i}$  em que  $\lambda_i$ s são os  $\min\{n, d\}$  maiores autovalores de  $\mathbf{P}\mathbf{P}^T$  ou  $\mathbf{P}^T\mathbf{P}$ , chamados de valores singulares.
- Geo
- Por convenção, as colunas de  $\mathbf{U}$ ,  $\mathbf{V}$  e  $\mathbf{D}$  são apresentadas em ordem não crescente de valores singulares.
  - A decomposição apresentada é também chamada de **SVD Completa**.



Note que,

$$\begin{aligned}\mathbf{P} &= \mathbf{UDV}^T \quad \text{e} \\ \mathbf{P}^T &= (\mathbf{UDV}^T)^T = (\mathbf{V}^T)^T \mathbf{D}^T \mathbf{U}^T = \mathbf{VDU}^T\end{aligned}$$

Então,

$$\begin{aligned}\mathbf{P}^T \mathbf{P} &= \mathbf{VDU}^T \mathbf{UDV}^T \\ &= \mathbf{VDDV}^T = \mathbf{VD}^2 \mathbf{V}^T\end{aligned}$$

Note ainda que,

$$\mathbf{P}^T \mathbf{P} \mathbf{V} = \mathbf{VD}^2 \mathbf{V}^T \mathbf{V} = \mathbf{VD}^2$$

indicando que  $\mathbf{V}$  é a matriz de autovalores de  $\mathbf{P}^T \mathbf{P}$  e  $\mathbf{D}^2$  é a matriz de autovalores correspondentes.

O mesmo raciocínio pode ser feito partindo de  $\mathbf{PP}^T$  e concluindo que  $\mathbf{U}$  é a matriz de autovalores de  $\mathbf{PP}^T$  e  $\mathbf{D}^2$  é a matriz de autovalores correspondentes.




## Observações:

- A **SVD truncada** descarta os elementos de  $\mathbf{D}$  em que  $\lambda_i = 0$  ou muito pequenos. Neste caso, são descartados também os autovetores correspondentes de  $\mathbf{U}$  e  $\mathbf{V}$ .
- Considere que mantemos apenas os  $k$  maiores elementos da diagonal de  $\mathbf{D}$ . Podemos representar a  $SVD_k$  por

$$\mathbf{P} \approx \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^T$$

ou



- Esta abordagem resulta em redução de dimensionalidade de  $\mathbf{P}$ .
- $\text{tr}(\mathbf{D}_r)/\text{tr}(\mathbf{D})$  fornece a energia (ou informação) retida pela SVD truncada.



## Representação Gráfica: Biplot de Gabriel

*Biplots representam dados de uma matriz **S** através de sua decomposição no produto de duas matrizes:  $\mathbf{S} = \mathbf{XY}^T$ .*

*O nome Biplot se refere ao fato de que **dois** grupos de pontos da matriz original (linhas e colunas) são visualizados através do produto escalar.*

### Referências:

- Gabriel, K.R. (1971). "The Biplot Graphic Display of Matrices with Application to Principal Component Analysis." *Biometrika*, 58, 453-467.
- Greenacre, M. (2010). *Biplots in Practice*. Disponível em [www.fbbva.es/microsite/multivariate-statistics/biplots.html](http://www.fbbva.es/microsite/multivariate-statistics/biplots.html)



**Exemplo:** Matriz original e decomposição.

$$\begin{pmatrix} 8 & 2 & 2 & -6 \\ 5 & 0 & 3 & -4 \\ -2 & -3 & 3 & 1 \\ 2 & 3 & -3 & -1 \\ 4 & 6 & -6 & -2 \end{pmatrix} = \begin{pmatrix} 2 & 2 \\ 1 & 2 \\ -1 & 1 \\ 1 & -1 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 3 & 2 & -1 & -2 \\ 1 & -1 & 2 & -1 \end{pmatrix}$$

$$\mathbf{S} = \mathbf{XY}^T = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \mathbf{x}_3^T \\ \mathbf{x}_4^T \\ \mathbf{x}_5^T \end{pmatrix} (\mathbf{y}_1 \ \mathbf{y}_2 \ \mathbf{y}_3 \ \mathbf{y}_4) = \begin{pmatrix} \mathbf{x}_1^T \mathbf{y}_1 & \mathbf{x}_1^T \mathbf{y}_2 & \mathbf{x}_1^T \mathbf{y}_3 & \mathbf{x}_1^T \mathbf{y}_4 \\ \mathbf{x}_2^T \mathbf{y}_1 & \mathbf{x}_2^T \mathbf{y}_2 & \mathbf{x}_2^T \mathbf{y}_3 & \mathbf{x}_2^T \mathbf{y}_4 \\ \mathbf{x}_3^T \mathbf{y}_1 & \mathbf{x}_3^T \mathbf{y}_2 & \mathbf{x}_3^T \mathbf{y}_3 & \mathbf{x}_3^T \mathbf{y}_4 \\ \mathbf{x}_4^T \mathbf{y}_1 & \mathbf{x}_4^T \mathbf{y}_2 & \mathbf{x}_4^T \mathbf{y}_3 & \mathbf{x}_4^T \mathbf{y}_4 \\ \mathbf{x}_5^T \mathbf{y}_1 & \mathbf{x}_5^T \mathbf{y}_2 & \mathbf{x}_5^T \mathbf{y}_3 & \mathbf{x}_5^T \mathbf{y}_4 \end{pmatrix}$$

Imagens de Greenacre, 2010.



## Exemplo: Matriz original e decomposição.




Imagem de Greenacre, 2010.





- O produto escalar entre dois vetores é o comprimento da projeção do primeiro vetor no segundo, multiplicado pelo comprimento do segundo vetor.

$$\mathbf{X}'\mathbf{Y} = \|\mathbf{X}\| \|\mathbf{Y}\| \cos(\theta)$$




Imagem de Greenacre, 2010.

- O R tem a função `biplot` no pacote `stats`.



### Exemplo 1: Avaliação de filmes por usuários:

Dois grupos de assinantes de uma plataforma de streaming avaliaram 3 filmes de ficção (F1,F2,F3) e dois filmes de romance (R1,R2). O grupo 1 é formado por 4 usuários jovens e o grupo 2 é formado por 3 usuários idosos.

	F1	F2	F3	R1	R2
J1	8	8	9	3	4
J2	7	6	7	3	5
J3	8	9	9	2	4
J4	9	8	9	1	2
I1	3	2	2	9	8
I2	2	1	2	8	8
I3	3	2	2	7	8

Neste exemplo existem dois conceitos relacionados a filmes: Ficção e Romance  
No R podemos utilizar a função `svd(M)`.



## Exemplo 1: Avaliação de filmes por usuários


- Os conceitos (Ficção e Romance) envolvidos na matriz  $\mathbf{P}$  são revelados por  $\mathbf{U}$  e  $\mathbf{V}$ . A importância relativa destes conceitos é revelada por  $\mathbf{D}$ .
- $\mathbf{U}$  revela a avaliação feita pelos Grupos 1 e 2 (jovens e idosos).
- $\mathbf{V}^T$  revela a avaliação dos tipos de filmes (ficção e romance).
- Note que apesar de  $\mathbf{P}$  possuir rank 5, apenas dois dos autovalores de  $\mathbf{P}\mathbf{P}^T$  possuem valores elevados, relativamente aos demais.
- Podemos então aplicar uma  $\text{SVD}_2$  para aproximar  $\mathbf{P}$ , i.e.,

$$\begin{pmatrix} 8 & 8 & 9 & 3 & 4 \\ 7 & 6 & 7 & 3 & 5 \\ 8 & 9 & 9 & 2 & 4 \\ 9 & 8 & 9 & 1 & 2 \\ 3 & 2 & 2 & 9 & 8 \\ 2 & 1 & 2 & 8 & 8 \\ 3 & 2 & 2 & 7 & 8 \end{pmatrix} \approx \begin{pmatrix} -0.5 & -0.2 \\ -0.4 & -0.1 \\ -0.5 & -0.3 \\ -0.4 & -0.4 \\ -0.3 & 0.5 \\ -0.3 & 0.5 \\ -0.3 & 0.4 \end{pmatrix} \begin{pmatrix} 32.5 & 0.00 \\ 0.0 & 15.8 \end{pmatrix} \begin{pmatrix} -0.5 & -0.5 & -0.5 & -0.3 & -0.4 \\ -0.2 & -0.3 & -0.3 & 0.6 & 0.6 \end{pmatrix}$$



## Exemplo 1: Avaliação de filmes por usuários

- Interpretação?



- A informação retida é de cerca de 94% da informação original.
- Observação: em estudos reais a interpretação/visualização geralmente não é trivial.




## Exemplo 2: Redução de Dimensão de Imagens


- Uma imagem pode ser representada como uma matriz de píxeis. Esta matriz pode ser comprimida utilizando SVD.
- No caso de imagens coloridas, cada cor (*red*, *green*, *blue*) forma uma matriz em separado.
- O programa R `svdJudytte.R` apresenta a redução de uma imagem em matrizes de rank inferior. Alguns resultados, para diferentes reduções, são apresentados a seguir. A imagem original possui Rank 570.




Rank 570



Rank 5



Rank 20



Rank 99



## Observações

- Uma importante área de aplicação é em dados de texto, como a comparação de documentos através da frequência de certas palavras. Considere, por exemplo, a seguinte matriz que apresenta a contagem de seis palavras (*lion*, *tiger*, *cheetah*, *jaguar*, *porsche*, *ferrari*) em seis documentos<sup>1</sup>.

$$\mathbf{D} = \begin{matrix} & \begin{matrix} \text{Doc1} & \text{Doc2} & \text{Doc3} & \text{Doc4} & \text{Doc5} & \text{Doc6} \end{matrix} \\ \begin{pmatrix} 2 & 2 & 1 & 2 & 0 & 0 \\ 2 & 3 & 3 & 3 & 0 & 0 \\ 1 & 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 3 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 2 & 2 & 2 \end{pmatrix} \end{matrix}$$

Podemos utilizar SVD para aproximar  $\mathbf{P}$  e captar os conceitos escondidos (variáveis latentes) na matriz de dados. Este tipo de estudo é conhecido como Análise de Semântica Latente (*Latent Semantic Analysis*).

- SVD é uma técnica de redução dimensional mais apropriada para dados Esparsos. A análise de componentes principais (PCA) pode destruir a esparsidade dos dados.
- Remoção de ruídos também é uma aplicação de SVD.

---

<sup>1</sup>Aggarwall, 2021. Neste texto é utilizada a notação  $\mathbf{D} = \mathbf{Q}\mathbf{\Sigma}\mathbf{P}^T$

