

Análise Multivariada

Distribuição Normal Multivariada

Prof. George von Borries

Departamento de Estatística
Universidade de Brasília

2023




Normal Univariada: $N(\mu, \sigma^2)$

Definição (Normal Univariada)

$$g(y) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(\frac{-(y - \mu)^2}{2\sigma^2}\right)$$

onde $y \in \mathbb{R}$, $-\infty < \mu < \infty$, $\sigma > 0$.



Normal Multivariada: $N_p(\mu, \Sigma)$

Definição (Normal Multivariada)

A densidade da normal p -dimensional para um vetor aleatório $\mathbf{Y}^T = \{Y_1, Y_2, \dots, Y_p\}$ tem a forma,

$$f(\mathbf{y}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[\frac{-(\mathbf{y} - \mu)^T \Sigma^{-1} (\mathbf{y} - \mu)}{2} \right]$$

onde $\mu = (\mu_1, \dots, \mu_p)^T$, $-\infty < y_i < \infty$, $i = 1, 2, \dots, p$ e $\Sigma > 0$.

- Note que para $p = 1$, a normal multivariada se reduz a normal univariada.
- Para $p = 2$ temos a normal bivariada.



Normal Bivariada: $N_2(\mu, \Sigma)$

Neste caso a Normal Multivariada se reduz a,

$$f(y_1, y_2) = \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho_{12}^2)}} \times \exp \left\{ -\frac{1}{2(1-\rho_{12}^2)} \left[\left(\frac{y_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{y_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{y_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{y_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right] \right\}$$

em que

$$\mu_1 = E(Y_1), \mu_2 = E(Y_2), \sigma_{11} = \text{Var}(Y_1), \sigma_{22} = \text{Var}(Y_2), \text{ e} \\ \rho_{12} = \sigma_{12}/(\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}) = \text{Cor}(Y_1, Y_2).$$

Note que a inversa da matriz de variância-covariância,


$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{12} & \sigma_{22} \end{bmatrix} \quad \text{é} \quad \Sigma^{-1} = \frac{1}{\sigma_{11}\sigma_{22} - \sigma_{12}^2} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix}$$




Normal Bivariada

Distribuição Normal Bivariada

$$\mu_1 = 0, \mu_2 = 0, \sigma_{11} = 1, \sigma_{22} = 1, \sigma_{12} = 0$$




Borries




Normal Bivariada

Distribuição Normal Bivariada

$$\mu_1 = 0, \mu_2 = 0, \sigma_{11} = 1, \sigma_{22} = 1, \sigma_{12} = 0.5$$




Borries




Normal Bivariada

Distribuição Normal Bivariada

$$\mu_1 = 0, \mu_2 = 0, \sigma_{11} = 1, \sigma_{22} = 1, \sigma_{12} = 0.9$$



Borries



Normal Bivariada

George von Borries

Obs: utilize Adobe Reader DC para ver a animação na figura acima.



Padronização

Resultado 1: Seja $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Um vetor padronizado pode ser obtido de duas formas:

- 1 $\mathbf{Z} = (\mathbf{M}^T)^{-1}(\mathbf{Y} - \boldsymbol{\mu})$, com $\boldsymbol{\Sigma} = \mathbf{M}^T \mathbf{M}$ fatorado pela decomposição de Cholesky ou
- 2 $\mathbf{Z} = (\boldsymbol{\Sigma}^{1/2})^{-1}(\mathbf{Y} - \boldsymbol{\mu})$, sendo $\boldsymbol{\Sigma}^{1/2}$ a raiz quadrada simétrica de $\boldsymbol{\Sigma}$.

Assim, $\mathbf{Z} \sim N_p(\mathbf{0}, \mathbf{I}_p)$.



Definição:

\mathbf{Y} tem distribuição normal multivariada $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ se a função geradora de momentos (fgm) é

$$M_{\mathbf{Y}}(\mathbf{t}) = \exp \left\{ \mathbf{t}^T \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t} \right\}.$$

para todo $\mathbf{t} \in \mathbb{R}^n$, $\boldsymbol{\Sigma}$ simétrica, positiva semidefinida e $\boldsymbol{\mu} \in \mathbb{R}^n$.

Nota: Se $\boldsymbol{\Sigma}$ singular, $f(\mathbf{y})$ não é definida, mas a função geradora de momentos continua válida.



Resultado 2:

- 1 Seja \mathbf{a} é um vetor de constantes. Se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então $\mathbf{a}^T \mathbf{Y} \sim N_p(\mathbf{a}^T \boldsymbol{\mu}, \mathbf{a}^T \boldsymbol{\Sigma} \mathbf{a})$.
- 2 Seja $\mathbf{A}_{(q \times p)}$ uma matriz de constantes de rank $q \leq p$. Se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então $\mathbf{A}\mathbf{Y} \sim N_q(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T)$.
- 3 Seja $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Considere $\mathbf{X} = \mathbf{A}\mathbf{Y} + \mathbf{b}$, com $\mathbf{A}_{(m \times p)}$ e $\mathbf{b} \in \mathbb{R}^m$. Então $\mathbf{X} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T)$.

Resultado 3: (Ver prova em J&W, pág. 153)


- Se $\boldsymbol{\Sigma}$ é positiva definida, então $\boldsymbol{\Sigma}^{-1}$ existe, é positiva definida e

$$\boldsymbol{\Sigma} \mathbf{e} = \lambda \mathbf{e} \Rightarrow \boldsymbol{\Sigma}^{-1} \mathbf{e} = \frac{1}{\lambda} \mathbf{e}$$



Resultado 4:

Seja $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Então contornos de densidade constante são elipsóides definidos por \mathbf{Y} tais que $(\mathbf{Y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu}) = a$. Os elipsóides são centrados em $\boldsymbol{\mu}$ e tem eixos $\pm \sqrt{a\lambda_i}$, $i = 1, \dots, p$.



Resultado 5:

Se $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então $\underbrace{(\mathbf{Y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu})}_{\text{distância estatística}} \sim \chi_p^2$, sendo $|\boldsymbol{\Sigma}| > 0$.

Resultado 6:

O elipsóide de \mathbf{Y} com valores $(\mathbf{Y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha)$, tem probabilidade $(1 - \alpha)$.

Resultado 7:

Sejam $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, \mathbf{A} e \mathbf{B} matrizes apropriadas. \mathbf{AY} e \mathbf{BY} são independentes se $\mathbf{A}\boldsymbol{\Sigma}\mathbf{B}^\top = \mathbf{0}$.



Resultado 8: (Ver J&W, páginas 157 e 158)

Todos os subconjuntos de $\mathbf{Y}_{(n \times p)} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ tem distribuição normal.

Não existe perda de generalidade em escrever \mathbf{Y} como

$$\mathbf{Y} = \begin{bmatrix} \mathbf{Y}^a \\ \mathbf{Y}^b \end{bmatrix}$$

sendo $\mathbf{Y}^a_{(n \times m)}$ e $\mathbf{Y}^b_{(n \times k)}$, $k = p - m$. Da mesma forma teremos,

$$\boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{bmatrix}$$

com as dimensões apropriadas. Assim, $\mathbf{Y}^a \sim N_m(\boldsymbol{\mu}_a, \boldsymbol{\Sigma}_{aa})$ e $\mathbf{Y}^b \sim N_{p-m}(\boldsymbol{\mu}_b, \boldsymbol{\Sigma}_{bb})$.

Importante: Este teorema diz que toda distribuição marginal de \mathbf{Y} é também normal, com média e variâncias associadas ao vetor de variáveis que formam a marginal.



Resultado 9:

Se os vetores \mathbf{Y}_1 e \mathbf{Y}_2 tem distribuição conjunta Normal Multivariada e $\Sigma_{12} = \mathbf{0}$, então \mathbf{Y}_1 e \mathbf{Y}_2 são independentes.

Dica: A prova é feita utilizando a função geradora de momentos e verificando que $M_{\mathbf{Y}_1, \mathbf{Y}_2}(\mathbf{t}_1, \mathbf{t}_2) = M_{\mathbf{Y}_1}(\mathbf{t}_1)M_{\mathbf{Y}_2}(\mathbf{t}_2)$ se, e somente se, $\Sigma_{12} = \mathbf{0}$. (Note que $\Sigma_{12} = \Sigma_{21}$)

Resultado 10:

- 1 Normal multivariada \Rightarrow marginais com dist. normal.
- 2 Marginais com dist. normal \nRightarrow normal multivariada.
- 3 Marginais com dist. não normal \Rightarrow dist. não é normal multivariada.

Resultado 11:

A distribuição $N_p(\mu, \Sigma)$ é simétrica em torno de μ .

Dica: Substituir \mathbf{y} por $\mu + \mathbf{a}$ e verificar que $f(\mu + \mathbf{a}) = f(\mu - \mathbf{a})$.



Resultado 12: Distribuição Condicional

Sejam \mathbf{Y}_1 e \mathbf{Y}_2 com distribuição normal multivariada, tal que $\boldsymbol{\Sigma}_{12} \neq \mathbf{0}$.
Então, $f(\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2) \sim N_m(\boldsymbol{\mu}_{1.2}, \boldsymbol{\Sigma}_{1.2})$ com

$$\boldsymbol{\mu}_{1.2} = \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{y}_2 - \boldsymbol{\mu}_2)$$

e

$$\boldsymbol{\Sigma}_{1.2} = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}.$$

Resultado 13: Ver J&W, páginas 168 a 173

Os estimadores de Máxima Verossilhança de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ são $\hat{\boldsymbol{\mu}} = \bar{\mathbf{Y}}$ e $\hat{\boldsymbol{\Sigma}} = \frac{n-1}{n} \mathbf{S}$, com

$$\mathbf{S} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{Y}_j - \bar{\mathbf{Y}})(\mathbf{Y}_j - \bar{\mathbf{Y}})^T.$$

As estatísticas $\bar{\mathbf{Y}}$ e \mathbf{S} são suficientes.



Resultado 14: Versão multivariada do Teorema de Cochran

Seja $\mathbf{Y}_1, \dots, \mathbf{Y}_n$ uma amostra aleatória e tamanho n de uma distribuição normal p -variada, com média $\boldsymbol{\mu}$ e matriz de variância-covariância $\boldsymbol{\Sigma}$. Então,

- (a) $\bar{\mathbf{Y}} \sim N_p(\boldsymbol{\mu}, \frac{1}{n}\boldsymbol{\Sigma})$.
 - (b) $(n-1)\mathbf{S}$ tem distribuição de Wishart com $(n-1)$ graus de liberdade.
 - (c) $\bar{\mathbf{Y}}$ e \mathbf{S} são independentes.
- A distribuição de Wishart é análoga a χ^2 no caso univariado.
 - $\mathbf{W}_m(\cdot | \boldsymbol{\Sigma})$ é a distrib. de $\sum_{j=1}^m \mathbf{Z}_j \mathbf{Z}_j^T$ onde $\mathbf{Z}_j \stackrel{iid}{\sim} N_p(\mathbf{0}, \boldsymbol{\Sigma})$.
 - Esta distribuição é importante em estudos de regressão multivariada e análise de variância multivariada (MANOVA).



Resultado 14: Teorema Central do Limite

Seja $\sqrt{n}(\bar{\mathbf{Y}} - \boldsymbol{\mu}) \sim N_p(\mathbf{0}, \boldsymbol{\Sigma})$. Assim, $\bar{\mathbf{Y}}$ é aproximadamente $N_p(\boldsymbol{\mu}, \frac{1}{n}\boldsymbol{\Sigma})$.

Segue que $(\mathbf{Y} - \boldsymbol{\mu})^T \mathbf{S}^{-1} (\mathbf{Y} - \boldsymbol{\mu})$ é aproximadamente χ_p^2 para $(n - p)$ suficientemente grande.

Nota: Este resultado apresenta problemas em situações em que $n \approx p$ e $n < p$.



Investigando Normalidade Multivariada

Referências:

- C.J. Mecklin e D.J. Mundfrom (2004). An appraisal and bibliography of tests for multivariate normality. *International Statistical Review*, 72:123-138.

Mecklin e Mundfrom apresentam uma excelente revisão de procedimentos para teste de bondade de ajustamento para a normal multivariada.

- R.A. Johnson e D.W. Wichern (2007). *Applied multivariate statistical analysis*. Prentice Hall. Sexta Edição. Para abordagem geral, ver seção 4.6.
- A.C. Rencher e W.F. Christensen (2012). *Methods of Multivariate Analysis*. Wiley, Terceira Edição. Ver seção 4.4.2.



Estratégias gráficas:

- Avaliar se as marginais de \mathbf{Y} aparentam normalidade através de gráficos de probabilidade normal.
- Avaliar se pares de observações aparentam a forma elíptica esperada para populações normais.
- Verificar se existem observações atípicas.

Rencher e Christensen (2012) sugerem o seguinte procedimento:

- 1 Calcular as distâncias $D_i^2 = (\mathbf{y}_i - \bar{\mathbf{y}})^T \mathbf{S}^{-1} (\mathbf{y}_i - \bar{\mathbf{y}})$, $i = 1, \dots, n$.
- 2 Calcular $u_i = nD_i^2 / (n-1)^2$
- 3 Calcular $v_i = (i - \alpha) / (n - \alpha - \beta + 1)$, sendo $\alpha = (p-2)/2p$ e $\beta = (n-p-3)/(2(n-p-1))$. Quantis de uma $\text{Beta}(\alpha, \beta)$.
- 4 Plotar os pares $(u_{(i)}, v_i)$, $u_{(1)} \leq u_{(2)} \leq \dots \leq u_{(n)}$.
- 5 Padrão não linear sugere não normalidade.



Geração da Normal Multivariada

Referências:

- Rizzo, M.L. (2008). *Statistical computing with R*, Chapman & Hall/CRC.
- L. Han. *Generating multivariate normal data by using PROC IML*. Technical report, University of Georgia, Athens, GA.
- O R apresenta algumas funções para geração, como `mvrnorm` do pacote MASS e `rmvnorm` do pacote mvtnorm. A função `rmvnorm` possui os métodos `eigen`, `svd` e `chol` para geração da normal multivariada.



1 Geração por Decomposição Espectral

- Σ positiva definida $\Rightarrow \Sigma^{1/2}$ positiva definida.
- $\Sigma^{1/2} = \Gamma^T \Lambda^{1/2} \Gamma$.
- A decomposição espectral será $\Sigma = \Gamma^T \Lambda \Gamma$.
- Se fizermos $Q = \Sigma^{1/2}$, então a fatorização de Σ é $\Sigma = Q^T Q$.

Nota: Lembre que $\Gamma \Gamma^T = I$ e $\Gamma^T = \Gamma^{-1}$.

1. POR DECOMPOSIÇÃO ESPECTRAL

```
rmvn.eigen <-  
function(n, mu, Sigma) {  
  p <- length(mu)  
  ev <- eigen(Sigma, symmetric = TRUE)  
  lambda <- ev$values  
  V <- ev$vectors  
  R <- V %%% diag(sqrt(lambda)) %%% t(V)  
  Z <- matrix(rnorm(n*p), nrow = n, ncol = p)  
  X <- Z %%% R + matrix(mu, n, p, byrow = TRUE)  
  X  
}
```



2 Geração por Decomposição em Valores Singulares

- $\Sigma = \mathbf{U}\mathbf{D}\mathbf{V}^T$.
- \mathbf{U} : autovetores de $\Sigma\Sigma^T$.
- \mathbf{S} : diagonal da raiz dos autovalores de $\Sigma\Sigma^T$.
- \mathbf{V} : autovetores de $\Sigma^T\Sigma$.

Como Σ simétrica e positiva definida,

$\mathbf{U} = \mathbf{V}$ e $\Sigma^{1/2} = \mathbf{U}\mathbf{D}^{1/2}\mathbf{V}^T \equiv$ método espectral, porém menos eficiente.

```
# 2. POR DECOMPOSIÇÃO EM VALORES SINGULARES
```

```
rmvn.svd <-  
function(n, mu, Sigma) {  
  p <- length(mu)  
  S <- svd(Sigma)  
  R <- S$u %*% diag(sqrt(S$d)) %*% t(S$v)  
  Z <- matrix(rnorm(n*p), nrow=n, ncol=p)  
  X <- Z %*% R + matrix(mu, n, p, byrow=TRUE)  
  X  
}
```



3 Geração por Decomposição de Cholesky

- $\Sigma = Q^T Q$, sendo Q triangular superior.

```
# POR DECOMPOSIÇÃO DE CHOLESKY  
rmvn.cholesky <-  
function(n, mu, Sigma) {  
  p <- length(mu)  
  Q <- chol(Sigma)  
  Z <- matrix(rnorm(n*p), nrow=n, ncol=p)  
  X <- Z %*% Q + matrix(mu, n, p, byrow=TRUE)  
  X  
}
```

De forma geral,

- Fazer a decomposição de Σ (chame de D)
- Gerar uma matriz $Z_{n \times p}$ de valores da $N(0, 1)$
- Gerar $Y = \mu + Z * D$

Veja programa `geranp.R`.

